

Laboratorio 1: Series de Tiempo

CC3084 - Data Science | UVG | Semestre II 2026

Análisis del ingreso de viajeros internacionales a Guatemala (2009 - jun 2026).

Integrantes: Iris Ayala 23960, Jonathan Díaz 23837 y Anggie Quezada 23643

Cargar datos

(161036, 14)

	Año	Mes cod	Mes	Vía	Frontera	País	Región	Región dos	Regiones OMT	MCEO	Agrupar Reside
0	2009	1	Ene	Aérea	01 La Aurora	Albania	OTROS EUROPEOS	Europa	EUROPA MERIDIONAL	08 OTROS	Eu
1	2009	1	Ene	Aérea	01 La Aurora	Alemania	EUROPA	Europa	EUROPA OCCIDENTAL	04 EUROPA	Eu
2	2009	1	Ene	Aérea	01 La Aurora	Angola	OTROS PAISES DEL MUNDO	Otros Países Del Mundo	ÁFRICA CENTRAL	08 OTROS	Resi M
3	2009	1	Ene	Aérea	01 La Aurora	Arabia Saudita	OTROS ORIENTE MEDIO	Oriente Medio	ORIENTE MEDIO	08 OTROS	Resi M
4	2009	1	Ene	Aérea	01 La Aurora	Argelia	OTROS PAISES DEL MUNDO	Otros Países Del Mundo	ÁFRICA DEL NORTE	08 OTROS	Resi M

Análisis exploratorio


```

<class 'pandas.DataFrame'>
RangeIndex: 161036 entries, 0 to 161035
Data columns (total 14 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Año                                  161036 non-null  int64
1   Mes cod                             161036 non-null  int64
2   Mes                                  161036 non-null  str
3   Vía                                  161036 non-null  str
4   Frontera                             161036 non-null  str
5   País                                  161036 non-null  str
6   Región                              161036 non-null  str
7   Región dos                           161036 non-null  str
8   Regiones OMT                         161036 non-null  str
9   MCEO                                 161036 non-null  str
10  Agrupación Residencia                161036 non-null  str
11  Tipo de Viajero                      161036 non-null  str
12  Viajero                              161036 non-null  float64
13  Fecha                                161036 non-null  datetime64[us]
dtypes: datetime64[us](1), float64(1), int64(2), str(10)
memory usage: 17.2 MB

```

	count	unique	top	freq	mean	min	25%	50
Año	161036.0	NaN	NaN	NaN	2016.017543	2009.0	2012.0	2016
Mes cod	161036.0	NaN	NaN	NaN	6.416075	1.0	3.0	6
Mes	161036	12	Ene	14726	NaN	NaN	NaN	Na
Vía	161036	3	Terrestre	125873	NaN	NaN	NaN	Na
Frontera	161036	22	01 La Aurora	21424	NaN	NaN	NaN	Na
País	161036	235	Guatemala	6319	NaN	NaN	NaN	Na
Región	161036	17	EUROPA	32331	NaN	NaN	NaN	Na
Región dos	161036	11	Europa	54640	NaN	NaN	NaN	Na
Regiones OMT	161036	26	AMÉRICA CENTRAL	31362	NaN	NaN	NaN	Na
MCEO	161036	8	08 OTROS	73173	NaN	NaN	NaN	Na
Agrupación Residencia	161036	33	Europa	46761	NaN	NaN	NaN	Na
Tipo de Viajero	161036	4	Turista	117912	NaN	NaN	NaN	Na
Viajero	161036.0	NaN	NaN	NaN	324.697193	0.0	2.0	7
Fecha	161036	NaN	NaN	NaN	2016-06-19 22:24:29.365856	2009-01-01 00:00:00	2012-10-01 00:00:00	2016-03-01 00:00:00


Comportamiento temporal del número de viajeros



Se ve una tendencia creciente desde 2009 hasta 2019. Después hay una caída bien fuerte en marzo de 2020, que es cuando cerraron fronteras por la pandemia. Se mantiene bajo como un año y medio y luego empieza a recuperarse en 2022. También se nota un cambio de nivel entre 2022 y 2023.

Mayor cantidad de viajeros

País	
El Salvador	1.621398e+07
Guatemala	1.479233e+07
Estados Unidos de América	7.047843e+06
Honduras	2.788233e+06
México	1.808946e+06
Belize	1.328256e+06
Nicaragua	1.164343e+06
Cruceistas	1.078372e+06
Costa Rica	8.821797e+05
Colombia	5.610353e+05
Name: Viajero, dtype: float64	




El Salvador y Guatemala son los que más viajeros aportan, seguidos de Estados Unidos, Honduras y México. Con esto queda claro que la mayoría del movimiento es centroamericano y no tanto turismo internacional de otros continentes. Ojo que desde 2023 ya no se reporta cada país individual sino agrupaciones de mercado, entonces comparar país por país antes y después de 2023 hay que hacerlo con cuidado.

Regiones con mayor cantidad de viajeros

```
Región dos
América Del Centro      3.740653e+07
América Del Norte       9.383035e+06
Europa                  2.222621e+06
América Del Sur y el Caribe 1.447950e+06
Cruceistas              1.078372e+06
Asia                    4.217025e+05
Oceanía                 1.400472e+05
Oriente Medio           1.357125e+05
Cruceiros               2.603000e+04
Otros Países Del Mundo  2.511115e+04
0                        8.210000e+02
```

Name: Viajero, dtype: float64





América del Centro es la región que más aporta, muy por encima de las demás, luego América del Norte y después Europa. Esto va de la mano con lo que vimos en países: el grueso de los viajeros es movimiento regional, no turismo de larga distancia. Hay dos categorías rarísimas que casi no pesan nada en el total, seguro son registros mal clasificados pero no cambian las conclusiones.

Vías de ingreso y fronteras más utilizadas

```
Vía
Terrestre      3.199530e+07
Aérea          1.906385e+07
Marítima       1.228782e+06
Name: Viajero, dtype: float64
```

```
Frontera
01 La Aurora      1.903440e+07
07 Valle Nuevo   1.073234e+07
09 San Cristóbal  5.363009e+06
08 Pedro de Alvarado 4.393577e+06
10 La Ermita (Nueva Anguiatú) 2.879210e+06
20 Melchor de Mencos 2.349551e+06
13 El Cinchado / El Corinto 1.497006e+06
12 El Florido     1.221040e+06
11 Agua Caliente  1.154542e+06
15 El Carmen     1.023092e+06
Name: Viajero, dtype: float64
```




La vía Terrestre es la que más se usa por mucho, lo cual tiene sentido porque coincide con que El Salvador, Honduras y México son los países con más movimiento. La vía Aérea es la segunda y la Marítima es la que menos se usa. En fronteras, "01 La Aurora" (el aeropuerto) y "07 Valle Nuevo" (frontera con El Salvador) son las más usadas.

Valores faltantes, duplicados y valores atípicos

Valores nulos por columna:

Año	0
Mes cod	0
Mes	0
Vía	0
Frontera	0
País	0
Región	0
Región dos	0
Regiones OMT	0
MCEO	0
Agrupación Residencia	0
Tipo de Viajero	0
Viajero	0
Fecha	0
dtype: int64	

Filas totalmente duplicadas: 0



```

count      161036.000000
mean        324.697193
std         2387.745140
min          0.000000
25%          2.000000
50%          7.000000
75%         38.891667
max        92336.035067
Name: Viajero, dtype: float64

```


No hay valores nulos ni filas duplicadas, el dataset ya viene limpio. Sí hay valores que a simple vista parecen atípicos, como registros de 1 o 2 personas junto a registros de miles, pero es normal porque se están mezclando países muy distintos en volumen. También vimos en las notas que algunos valores de Viajero desde 2021 son decimales porque salen de una estimación de encuesta y no de un conteo exacto, así que esas pequeñas diferencias no son atípicos reales.

Estadística descriptiva

```

Año
2009      2.028776e+06
2010      2.152899e+06
2011      2.231456e+06
2012      2.299816e+06
2013      2.432169e+06
2014      2.762602e+06
2015      3.041643e+06
2016      3.496217e+06
2017      3.921460e+06
2018      4.256349e+06
2019      4.691820e+06
2020      1.266340e+06
2021      1.267768e+06
2022      4.316164e+06
2023      3.248709e+06
2024      3.593876e+06
2025      3.597238e+06
2026      1.682636e+06
Name: Viajero, dtype: float64

```



A nivel anual se ve clarísimo lo que veníamos comentando: la caída de 2020, la recuperación en 2021-2022, y el salto de nivel en 2023 por el cambio de metodología. Para comparar años de forma justa en todo el rango conviene usar Turista + Excursionista en vez del total.

División en entrenamiento y prueba

Al ser una serie de tiempo no podemos dividir aleatorio, hay que respetar el orden en el tiempo. Usamos el primer 70% de los meses para entrenamiento y el 30% final para prueba.

Total de meses: 210
Meses de entrenamiento: 147 → hasta 2021-03
Meses de prueba: 63 → desde 2021-04 hasta 2026-06
(131442, 14) (29594, 14)

Construcción de series de tiempo mensuales (con datos de entrenamiento)


Las categorías que elegimos como grupo son: Fronteras (top 3) y Países de residencia (top 3), además de la serie obligatoria del total mensual. El top 3 de fronteras y de países se calculó sobre el acumulado dentro del set de entrenamiento, no de un año en específico.

Serie obligatoria: total mensual

Fecha
2009-01-01 183505.590535
2009-02-01 149426.253908
2009-03-01 174237.227095
2009-04-01 182842.489917
2009-05-01 133194.667651
Name: Viajero, dtype: float64

Series por frontera (Top 3)

Top 3 fronteras: ['01 La Aurora', '07 Valle Nuevo', '09 San Cristóbal']




Las tres fronteras muestran la misma caída marcada en 2020 y recuperación posterior. La Aurora (aeropuerto) tiene el patrón más estacional por temporadas de vuelos, mientras que Valle Nuevo y San Cristóbal, al ser fronteras terrestres con El Salvador, se ven más estables y con menos variación estacional.

Series por país de residencia (Top 3)

Top 3 países: ['El Salvador', 'Guatemala', 'Estados Unidos de América']

Series mensuales por país de residencia (Top 3, entrenamiento)



El Salvador, Guatemala y Estados Unidos de América son los tres países con mayor acumulado en todo el período. Las series muestran la caída de 2020. Guatemala deja de aparecer como país de residencia desde 2023 debido al cambio de cobertura descrito en el dataset; sus ceros posteriores no deben interpretarse como ausencia real de viajeros.

Análisis de cada serie


--- Total mensual de viajeros ---

Inicio: 2009-01


Fin: 2021-03

Frecuencia: mensual (147 observaciones)

Serie mensual: Total mensual de viajeros



Descomposición aditiva: Total mensual de viajeros



ADF statistic: -1.9701

p-value: 0.2998

Valores críticos: {'1%': np.float64(-3.480118600110386), '5%': np.float64(-2.8833618426136196), '10%': np.float64(-2.578407034974382)}

→ No se rechaza H_0 : la serie NO es estacionaria en media (requiere diferenciación).

Con el total mensual: la gráfica confirma la tendencia de crecimiento hasta 2019, la caída de la pandemia y la recuperación después, o sea sí hay tendencia. En la descomposición se ve un patrón que se repite cada 12 meses, así que también hay estacionalidad (meses de temporada alta y baja de viajes). El residuo se dispara bastante alrededor de 2020, lo cual tiene sentido porque fue un evento raro y no ruido normal.

En el ACF los valores tardan mucho en bajar a cero, eso es señal de que la serie no es estacionaria en media. La prueba de Dickey-Fuller lo confirma cuando el p-value sale mayor a 0.05: en ese caso hay que diferenciar la serie (al menos una diferenciación regular, y probablemente una estacional de 12 meses) antes de poder ajustar un ARIMA.

Total mensual de viajeros — modelos (f-k)

Variabilidad relativa 1ra mitad: 0.194 | 2da mitad: 0.448 → transformacion log: True

Diferenciaciones regulares necesarias (d): 1 | ADF final p-value: 0.0265

ACF en lag 12 tras diferenciar: 0.195

auto_arima sugiere order=(1, 0, 1), AIC=86.67

Comparacion de modelos ARIMA candidatos (ordenado por AIC):


order	aic	bic	lb_pvalue
(1, 0, 1)	86.673962	98.635693	2.084589e-01
(2, 0, 0)	86.821650	98.783381	1.605987e-01
(1, 0, 0)	88.002997	96.974295	8.607710e-02
(2, 0, 2)	88.618876	106.561472	2.002111e-01
(1, 0, 2)	88.672449	103.624612	2.127401e-01
(2, 0, 1)	88.672748	103.624911	2.124546e-01
(0, 1, 1)	91.521634	97.488847	1.000000e+00
(1, 1, 0)	91.730028	97.697241	1.000000e+00
(0, 0, 2)	135.124110	147.085841	1.427954e-13
(0, 0, 1)	194.207539	203.178837	1.129275e-35
(0, 0, 0)	315.836269	321.817134	9.029936e-71

Mejor ARIMA: order=(1, 0, 1), AIC=86.67, BIC=98.64

Comparacion final de modelos (MAE, RMSE, y AIC/BIC donde aplica):

	mae	rmse	aic	bic
Prophet	104063.344171	113331.111632	NaN	NaN
ARIMA	102460.688311	119226.871343	86.673962	98.635693
Suavizamiento Exp.	197018.702226	217265.424973	3221.206380	3233.168110
Seasonal Naive	235730.913810	253203.387828	NaN	NaN
Holt-Winters	303348.494952	328303.031299	3138.765552	3186.612473

→ Mejor modelo segun RMSE en el conjunto de prueba: Prophet



f. Con la serie en logaritmo y una diferenciación ($d=1$, confirmado por la prueba ADF), `auto_arima` sugiere un $\text{ARIMA}(1,0,1)$ sobre la serie ya diferenciada, es decir un modelo con un término autorregresivo y uno de media móvil. Tiene sentido: en el ACF/PACF de la serie diferenciada (sección anterior) el patrón corto de 1-2 rezagos es justo lo que un (1,1) captura, y el ACF en el rezago 12 quedó casi en cero, por lo que no hizo falta un componente estacional (SARIMA) adicional.

g. Entre los candidatos probados, el $\text{ARIMA}(1,0,1)$ sobre la serie diferenciada es el que tiene menor AIC y BIC, y su p-value de Ljung-Box no es tan alto pero tampoco indica un problema grave de autocorrelación en los residuos. Modelos con menos parámetros (por ejemplo (0,0,0)) son mucho peores en AIC/BIC, así que agregar los términos AR y MA sí ayuda.

h-j. Comparando ARIMA con Prophet, Holt-Winters, suavizamiento exponencial y seasonal naive sobre el conjunto de prueba: Prophet y ARIMA quedan muy cerca en RMSE (ambos muy por debajo de los

demás), mientras que Holt-Winters y seasonal naive tienen el peor desempeño, señal de que el nivel de la serie cambió bastante entre 2022 y 2023 (el ajuste de metodología que ya habíamos visto en el EDA) y estos modelos más simples no logran adaptarse a ese salto.

k. El mejor modelo según RMSE en la serie total es **Prophet**, aunque ARIMA(1,0,1) tiene un MAE ligeramente mejor. Como la diferencia entre ambos es pequeña y Prophet maneja mejor el cambio de nivel post-pandemia/2023, se elige Prophet como modelo final para el total mensual.


Frontera: 01 La Aurora


--- 01 La Aurora ---

Inicio: 2009-01

Fin: 2021-03

Frecuencia: mensual (147 observaciones)





ADF statistic: -2.3661

p-value: 0.1515

Valores críticos: {'1%': np.float64(-3.4808880719210005), '5%': np.float64(-2.8836966192225284), '10%': np.float64(-2.5785857598714417)}

→ No se rechaza H_0 : la serie N0 es estacionaria en media (requiere diferenciación).

a-c. La serie va de enero 2009 a marzo 2021 (147 observaciones mensuales, entrenamiento). Al ser la frontera del aeropuerto La Aurora, se ve el mismo patrón de crecimiento hasta 2019, la caída de 2020 y una ligera recuperación al final del entrenamiento. En la descomposición se ve tendencia clara y una componente estacional marcada (más viajes en ciertos meses del año, consistente con temporadas de vuelos), y el residuo se dispara en 2020 igual que en el total.

d-e. El ACF de la serie original baja muy lento, señal de no estacionariedad en media, y la prueba ADF sobre la serie en niveles no rechaza la hipótesis nula (p-value > 0.05). La variabilidad también crece con el nivel de la serie (más dispersión en la segunda mitad del periodo), así que conviene una transformación logarítmica antes de modelar.

Variabilidad relativa 1ra mitad: 0.148 | 2da mitad: 0.404 → transformacion log: True

Diferenciaciones regulares necesarias (d): 0 | ADF final p-value: 0.0013

ACF en lag 12 tras diferenciar: -0.030

auto_arima sugiere order=(1, 0, 1), AIC=189.48

Comparacion de modelos ARIMA candidatos (ordenado por AIC):


order	aic	bic	lb_pvalue
(1, 0, 1)	189.477520	201.439250	4.100819e-01
(2, 0, 2)	189.934789	207.877385	4.846727e-01
(2, 0, 0)	190.788426	202.750156	3.172572e-01
(2, 0, 1)	190.805742	205.757905	4.594879e-01
(1, 0, 2)	190.931985	205.884148	4.474478e-01
(1, 0, 0)	194.755682	203.726979	1.029574e-01
(0, 0, 2)	226.102606	238.064337	4.818519e-07
(0, 0, 1)	275.066062	284.037359	3.530567e-25
(0, 0, 0)	396.704887	402.685752	1.252109e-52

Mejor ARIMA: order=(1, 0, 1), AIC=189.48, BIC=201.44

Comparacion final de modelos (MAE, RMSE, y AIC/BIC donde aplica):

	mae	rmse	aic	bic
ARIMA	24889.331287	30093.832986	189.477520	201.439250
Suavizamiento Exp.	40234.989633	45433.386527	2878.812653	2890.774384
Prophet	52210.973553	57946.065574	NaN	NaN
Holt-Winters	58057.188704	62601.602155	2737.949179	2785.796101
Seasonal Naive	75109.271508	79054.580121	NaN	NaN

→ Mejor modelo segun RMSE en el conjunto de prueba: ARIMA



e (cont.), f. Con la serie en logaritmo, la prueba ADF ya rechaza la no estacionariedad sin necesidad de diferenciar ($d=0$): la transformación logarítmica sola fue suficiente para estabilizar la media en esta serie, a diferencia del total. `auto_arima` sugiere un ARIMA(1,0,1), coherente con un ACF/PACF que decae rápido después del primer rezago.

g. El ARIMA(1,0,1) vuelve a ser el mejor por AIC y BIC entre los candidatos probados, con una mejora clara respecto a modelos más simples como (1,0,0) o (0,0,1).

h-j. Aquí el panorama cambia respecto al total: ARIMA tiene el menor MAE y RMSE de los cinco modelos, muy por debajo de suavizamiento exponencial, Prophet, Holt-Winters y seasonal naive. Esto tiene sentido porque La Aurora es una serie más simple (sin el salto de nivel tan marcado de 2023 que sí afecta más a otras series), así que un modelo ARIMA compacto le basta.

k. Para la frontera La Aurora, el mejor modelo es **ARIMA(1,0,1)** sobre la serie en logaritmo.


Frontera: 07 Valle Nuevo

--- 07 Valle Nuevo ---



Inicio: 2009-01

Fin: 2021-03

Frecuencia: mensual (147 observaciones)



Descomposición aditiva: 07 Valle Nuevo



ADF statistic: -1.6939
 p-value: 0.4342
 Valores críticos: {'1%': np.float64(-3.480118600110386), '5%': np.float64(-2.8833618426136196), '10%': np.float64(-2.578407034974382)}
 → No se rechaza H0: la serie N0 es estacionaria en media (requiere diferenciación).

a-c. Igual rango de fechas y frecuencia mensual que las demás series (147 meses de entrenamiento). Valle Nuevo es la frontera terrestre con El Salvador, y su gráfico muestra un crecimiento más moderado que La Aurora, con la misma caída de 2020 pero una recuperación algo más lenta. La descomposición muestra tendencia y una estacionalidad más suave que en La Aurora, coherente con que el tránsito terrestre fronterizo depende menos de temporadas turísticas.

d-e. La variabilidad relativa también crece bastante entre la primera y la segunda mitad del periodo, así que se necesita transformación logarítmica. El ACF decae lento en niveles y la prueba ADF sobre la serie en logaritmo tampoco rechaza la no estacionariedad todavía, por lo que hace falta diferenciar.

Variabilidad relativa 1ra mitad: 0.308 | 2da mitad: 0.483 → transformacion log: True

Diferenciaciones regulares necesarias (d): 1 | ADF final p-value: 0.0000

ACF en lag 12 tras diferenciar: -0.000

auto_arima sugiere order=(1, 0, 1), AIC=319.82

Comparacion de modelos ARIMA candidatos (ordenado por AIC):


order	aic	bic	lb_pvalue
(1, 0, 1)	319.816470	331.778201	5.206123e-02
(2, 0, 0)	319.858241	331.819971	3.419255e-02
(0, 1, 1)	320.526497	326.493711	9.885808e-01
(2, 0, 2)	321.014598	338.957194	1.063136e-02
(1, 0, 2)	321.737755	336.689918	4.348766e-02
(2, 0, 1)	321.761446	336.713609	4.593362e-02
(1, 1, 0)	321.816832	327.784045	9.724448e-01
(1, 0, 0)	322.270748	331.242046	6.542289e-03
(0, 0, 2)	359.802285	371.764016	7.843665e-11
(0, 0, 1)	400.528957	409.500255	1.882893e-27
(0, 0, 0)	481.453935	487.434800	2.357036e-66

Mejor ARIMA: order=(1, 0, 1), AIC=319.82, BIC=331.78

Comparacion final de modelos (MAE, RMSE, y AIC/BIC donde aplica):

	mae	rmse	aic	bic
Prophet	16562.321197	22229.875278	NaN	NaN
ARIMA	22875.904677	27436.678035	319.816470	331.778201
Seasonal Naive	47271.248422	52623.206778	NaN	NaN
Suavizamiento Exp.	48404.400561	53655.829576	2790.343139	2802.304869
Holt-Winters	59838.380193	65198.753459	2764.641671	2812.488593

→ Mejor modelo segun RMSE en el conjunto de prueba: Prophet



e (cont.), f. Con una diferenciación regular ($d=1$) sobre la serie en logaritmo, la prueba ADF ya rechaza la no estacionariedad con claridad. `auto_arima` sugiere nuevamente un $ARIMA(1,0,1)$ sobre la serie diferenciada, y el ACF en el rezago 12 queda prácticamente en cero, por lo que no se agregó componente estacional.

g. El $ARIMA(1,0,1)$ es el mejor por AIC, aunque un $(0,1,1)$ también compite de cerca y tiene el p-value de Ljung-Box más alto (residuos más parecidos a ruido blanco). Aun así, el $(1,0,1)$ sobre la serie diferenciada gana por AIC/BIC.

h-j. En esta serie, Prophet tiene el mejor MAE y RMSE de los cinco modelos, seguido por ARIMA; seasonal naive, suavizamiento exponencial y Holt-Winters quedan bastante peor. Esto sugiere que Valle Nuevo también tiene cambios de nivel entre periodos que Prophet captura mejor que un modelo de suavizado clásico.

k. Para Valle Nuevo, el mejor modelo es **Prophet**, con el $ARIMA(1,0,1)$ como segunda opción cercana.


Frontera: 09 San Cristóbal

--- 09 San Cristóbal ---


Inicio: 2009-01

Fin: 2021-03

Frecuencia: mensual (147 observaciones)



Descomposición aditiva: 09 San Cristóbal



ADF statistic: -1.7378

p-value: 0.4117

Valores críticos: {'1%': np.float64(-3.480118600110386), '5%': np.float64(-2.8833618426136196), '10%': np.float64(-2.578407034974382)}

→ No se rechaza H_0 : la serie N0 es estacionaria en media (requiere diferenciación).

a-c. Misma cobertura temporal y frecuencia mensual (147 meses de entrenamiento). San Cristóbal es la frontera con menor volumen de las tres, y su gráfico muestra un crecimiento más discreto, con la caída de 2020 y una recuperación visible pero de menor magnitud en términos absolutos. La descomposición muestra tendencia y una estacionalidad presente aunque de menor amplitud que en las otras dos fronteras (acorde a su menor volumen total), y el residuo también se dispara en 2020.

d-e. La variabilidad relativa crece bastante entre la primera y la segunda mitad de la serie (es la más marcada de las tres fronteras), así que se aplica la transformación logarítmica. El ACF decae lento y la prueba ADF sobre la serie en logaritmo tampoco alcanza a rechazar la no estacionariedad, así que se necesita diferenciar.

Variabilidad relativa 1ra mitad: 0.401 | 2da mitad: 0.551 → transformación log: True

Diferenciaciones regulares necesarias (d): 2 | ADF final p-value: 0.0000

ACF en lag 12 tras diferenciar: 0.056

```

auto_arima sugiere order=(1, 0, 1), AIC=301.08
Comparacion de modelos ARIMA candidatos (ordenado por AIC):
  order      aic      bic    lb_pvalue
(1, 0, 1) 301.076704 313.038434 4.099218e-01
(2, 0, 0) 301.088636 313.050366 4.122869e-01
(1, 0, 0) 302.835975 311.807273 3.254525e-01
(2, 0, 1) 302.952259 317.904422 4.218743e-01
(1, 0, 2) 303.056294 318.008457 4.100254e-01
(2, 0, 2) 304.635080 322.577675 4.514353e-01
(0, 0, 2) 317.664958 329.626688 8.916251e-05
(0, 2, 1) 324.675706 330.629174 1.920086e-02
(0, 0, 1) 348.475026 357.446324 3.075313e-15
(1, 2, 0) 388.363480 394.316948 2.094311e-02
(0, 0, 0) 407.569604 413.550469 4.798608e-48


```

Mejor ARIMA: order=(1, 0, 1), AIC=301.08, BIC=313.04

Comparacion final de modelos (MAE, RMSE, y AIC/BIC donde aplica):

	mae	rmse	aic	bic
Prophet	16125.877649	18509.090888	NaN	NaN
Suavizamiento Exp.	18058.339895	20711.694607	2640.526319	2652.488049
ARIMA	21647.264052	24154.811159	301.076704	313.038434
Seasonal Naive	30741.772222	34675.799048	NaN	NaN
Holt-Winters	34015.131359	37404.938474	2616.656219	2664.503140

→ Mejor modelo segun RMSE en el conjunto de prueba: Prophet



e (cont.), f. Esta serie necesitó **dos** diferenciaciones regulares ($d=2$) para que la prueba ADF rechazara la no estacionariedad; es la única de las cuatro series de esta parte que necesitó una segunda diferenciación. `auto_arima` sugiere un ARIMA(1,0,1) sobre la serie ya diferenciada, con un ACF en el rezago 12 cercano a cero (sin necesidad de componente estacional).

g. El ARIMA(1,0,1) vuelve a ser el mejor por AIC y BIC, y en este caso su p-value de Ljung-Box es el más alto de las cuatro series analizadas en esta parte, señal de residuos bien comportados.

h-j. Prophet tiene el menor MAE y RMSE, seguido de suavizamiento exponencial (que aquí funciona mejor que en las otras series, probablemente porque San Cristóbal tiene una tendencia más suave y menos cambios abruptos de nivel). ARIMA queda en tercer lugar, y Holt-Winters junto con seasonal naive son los que peor desempeño tienen.

k. Para San Cristóbal, el mejor modelo también es **Prophet**.


Países de residencia: análisis completo

Los Top 3 se determinaron con el acumulado de todo el período, mientras que cada modelo se ajusta exclusivamente con el conjunto de entrenamiento.


Países analizados: ['El Salvador', 'Guatemala', 'Estados Unidos de América']
Período de prueba: 2021-04 a 2026-06


País: El Salvador

--- El Salvador ---
Inicio: 2009-01
Fin: 2021-03
Frecuencia: mensual (147 observaciones)



Descomposición aditiva: El Salvador





ADF statistic: -1.7807

p-value: 0.3901

Valores críticos: {'1%': np.float64(-3.4808880719210005), '5%': np.float64(-2.8836966192225284), '10%': np.float64(-2.5785857598714417)}

→ No se rechaza H_0 : la serie NO es estacionaria en media (requiere diferenciación).

Variabilidad relativa 1ra mitad: 0.244 | 2da mitad: 0.528 → transformacion log: True

Diferenciaciones regulares necesarias (d): 1 | ADF final p-value: 0.0000

ACF en lag 12 tras diferenciar: -0.014

auto_arima sugiere order=(3, 0, 2), AIC=454.58

Comparacion de modelos ARIMA candidatos (ordenado por AIC):


order	aic	bic	lb_pvalue
(3, 0, 2)	454.577361	475.510389	0.261996
(2, 0, 3)	455.108859	476.041887	0.339678
(4, 0, 2)	456.164662	480.088123	0.360003
(3, 0, 3)	456.449828	480.373288	0.295751
(4, 0, 3)	456.713377	483.627270	0.363568
(3, 0, 1)	464.784549	482.727144	0.001502
(4, 0, 1)	464.989753	485.922781	0.014360
(2, 0, 1)	471.721866	486.674029	0.001109
(2, 0, 2)	475.557770	493.500365	0.000312
(3, 1, 0)	483.173230	495.107657	0.149407
(0, 1, 2)	483.384494	492.335314	0.109277

Mejor ARIMA: order=(3, 0, 2), AIC=454.58, BIC=475.51

Comparacion final de modelos (MAE, RMSE, y AIC/BIC donde aplica):

	mae	rmse	aic	bic
Prophet	53250.022900	56537.204270	NaN	NaN
ARIMA	81943.499478	90973.881834	454.577361	475.510389
Suavizamiento Exp.	98392.575486	109330.808672	2921.792256	2933.753986
Holt-Winters	100120.836769	109673.630032	2880.766063	2928.612985
Seasonal Naive	107474.047258	117633.371952	NaN	NaN

→ Mejor modelo segun RMSE en el conjunto de prueba: Prophet



La serie no es estacionaria en media (ADF $p=0.3901$); `log1p` estabiliza la varianza y una diferencia logra ADF $p<0.001$. El ARIMA(3,0,2) sobre la serie transformada tiene residuos compatibles con ruido blanco (Ljung-Box $p=0.262$), pero **Prophet** obtiene el menor RMSE de prueba (56,537) y es el modelo seleccionado.


País: Guatemala

--- Guatemala ---

Inicio: 2009-01


Fin: 2021-03

Frecuencia: mensual (147 observaciones)



Descomposición aditiva: Guatemala

Viajero



ADF statistic: -2.0911

p-value: 0.2481

Valores críticos: {'1%': np.float64(-3.480500383888377), '5%': np.float64(-2.8835279559405045), '10%': np.float64(-2.578495716547007)}

→ No se rechaza H_0 : la serie NO es estacionaria en media (requiere diferenciación).

Variabilidad relativa 1ra mitad: 0.259 | 2da mitad: 0.423 → transformacion log: True

Diferenciaciones regulares necesarias (d): 1 | ADF final p-value: 0.0365

ACF en lag 12 tras diferenciar: 0.364

auto_arima sugiere order=(1, 0, 2), AIC=26.71

Comparacion de modelos ARIMA candidatos (ordenado por AIC):


order	aic	bic	lb_pvalue
(1, 0, 2)	26.709933	41.662096	8.880996e-02
(2, 0, 1)	27.720386	42.672549	2.954103e-02
(0, 1, 2)	28.151954	37.102774	9.999998e-01
(1, 0, 3)	28.326484	46.269079	8.220919e-02
(2, 0, 2)	28.410605	46.353201	8.302017e-02
(2, 0, 3)	29.743086	50.676114	9.847520e-02
(1, 0, 1)	31.120196	43.081926	1.241499e-03
(1, 1, 0)	39.689902	45.657115	9.999997e-01
(0, 0, 3)	57.701021	72.653184	7.242202e-09
(0, 0, 2)	77.845091	89.806821	4.027230e-16
(0, 0, 1)	119.491582	128.462879	2.636111e-42

Mejor ARIMA: order=(1, 0, 2), AIC=26.71, BIC=41.66

Comparacion final de modelos (MAE, RMSE, y AIC/BIC donde aplica):

	mae	rmse	aic	bic
Holt-Winters	32167.735095	52983.778319	2842.765428	2890.612350
Suavizamiento Exp.	44804.586138	54542.349434	2935.184551	2947.146282
Prophet	52582.785910	55461.839777	NaN	NaN
Seasonal Naive	41032.626984	58176.300294	NaN	NaN
ARIMA	64165.465730	68230.045548	26.709933	41.662096

→ Mejor modelo segun RMSE en el conjunto de prueba: Holt-Winters



La serie no es estacionaria (ADF $p=0.2481$); `log1p` y una diferencia reducen el ADF a $p=0.0365$. Holt-Winters obtiene el menor RMSE (52,984), pero desde 2023 la fuente no reporta Guatemala en la variable País. Los ceros representan ausencia de cobertura, sesgan las métricas y hacen que esta selección no sea operativamente válida después de 2022.

País: Estados Unidos de América


--- Estados Unidos de América ---

Inicio: 2009-01


Fin: 2021-03

Frecuencia: mensual (147 observaciones)

Serie mensual: Estados Unidos de América



Descomposición aditiva: Estados Unidos de América



ADF statistic: -3.1223

p-value: 0.0249

Valores críticos: {'1%': np.float64(-3.480500383888377), '5%': np.float64(-2.8835279559405045), '10%': np.float64(-2.578495716547007)}

→ Se rechaza H_0 : la serie es estacionaria en media.

Variabilidad relativa 1ra mitad: 0.263 | 2da mitad: 0.471 → transformacion log: True

Diferenciaciones regulares necesarias (d): 1 | ADF final p-value: 0.0307

ACF en lag 12 tras diferenciar: 0.056

auto_arima sugiere order=(1, 0, 4), AIC=388.12

Comparacion de modelos ARIMA candidatos (ordenado por AIC):


order	aic	bic	lb_pvalue
(1, 0, 4)	388.116448	409.049476	0.997302
(0, 0, 5)	388.173798	409.106826	0.997254
(1, 0, 5)	390.061618	413.985078	0.997595
(2, 0, 4)	390.069460	413.992921	0.997547
(0, 0, 4)	391.182392	409.124988	0.836094
(2, 0, 5)	391.265745	418.179638	0.997296
(2, 0, 3)	415.887241	436.820269	0.093905
(1, 0, 3)	425.064288	443.006883	0.012719
(1, 1, 0)	434.323418	440.290632	0.545888
(0, 1, 4)	436.276991	451.195024	0.702988
(0, 0, 3)	451.931727	466.883890	0.000066

Mejor ARIMA: order=(1, 0, 4), AIC=388.12, BIC=409.05

Comparacion final de modelos (MAE, RMSE, y AIC/BIC donde aplica):

	mae	rmse	aic	bic
ARIMA	28360.755355	32195.269380	388.116448	409.049476
Prophet	30766.867127	34420.610675	NaN	NaN
Suavizamiento Exp.	35807.185772	39881.201232	2693.097464	2705.059194
Seasonal Naive	41167.828272	44196.197713	NaN	NaN
Holt-Winters	43728.438078	47961.403974	2514.999364	2562.846286

→ Mejor modelo segun RMSE en el conjunto de prueba: ARIMA



La serie original rechaza raíz unitaria (ADF $p=0.0249$), aunque tras `log1p` la rutina requiere una diferencia (ADF $p=0.0307$). El **ARIMA(1,0,4)** presenta residuos sin autocorrelación (Ljung-Box $p=0.997$) y logra el menor RMSE de prueba (32,195), por lo que es el modelo seleccionado.

Análisis comparativo

Se usan cuatro indicadores comparables dentro de cada categoría:

- **Estacionalidad:** fuerza estacional $\$1 - \text{Var}(R) / \text{Var}(S+R)\$$ de la descomposición aditiva.
- **Crecimiento:** pendiente mensual de 2009-2019 como porcentaje de la media.
- **Volatilidad:** desviación estándar del residuo de la descomposición como porcentaje de la media.
- **Pandemia:** reducción de la media mensual de 2020 frente a 2019.

Fronteras





	fuerza_estacional	crecimiento_mensual_pct	volatilidad_pct	caida_pandemia_pct
01 La Aurora	0.568	0.429	11.894	72.306
07 Valle Nuevo	0.344	0.754	19.289	80.726
09 San Cristóbal	0.245	1.169	26.647	73.131

Mayor estacionalidad: 01 La Aurora
 Mayor crecimiento: 09 San Cristóbal
 Mayor volatilidad: 09 San Cristóbal
 Mayor impacto pandémico: 07 Valle Nuevo

Países

	fuerza_estacional	crecimiento_mensual_pct	volatilidad_pct	caida_pandemia_pct
El Salvador	0.367	0.978	20.039	74.880
Guatemala	0.293	0.900	25.424	70.244
Estados Unidos de América	0.731	0.374	14.077	73.663

Mayor estacionalidad: Estados Unidos de América
 Mayor crecimiento: El Salvador
 Mayor volatilidad: Guatemala
 Mayor impacto pandémico: El Salvador



Hallazgos para la toma de decisiones

Los indicadores anteriores permiten concentrar promoción y capacidad operativa en los meses de mayor estacionalidad, distinguir crecimiento estructural de variación mensual y dimensionar la recuperación posterior a 2020. La Aurora requiere planificación especialmente estacional por su papel aéreo, mientras que las fronteras terrestres reflejan movilidad regional de mayor frecuencia. El Salvador y Estados Unidos de América mantienen cobertura reciente y son más útiles para monitorear mercados. Guatemala no debe usarse para decisiones posteriores a 2022 sin recuperar una fuente compatible, porque el cero observado es metodológico.